

BSL 1.1 AI APPLIANCE

Ihre KI-Plattform. Einfach betreibbar.

Modelle, Services, Benutzer und Betrieb
auf Ihrer Infrastruktur.

LOCAL-FIRST

HYBRID

BSL 1.1


QUALITYMINDS



Produktive KI ist mehr als ein Modell

Sechs Grenzen entscheiden, ob aus einem Experiment ein nutzbarer Dienst wird.

- Installation
- Netzwerk
- Modelle
- GitOps
- Identität
- Anwendungen




EINE APPLIANCE STATT SECHS BAUSTEILEN

Ein Control Plane macht KI zur Appliance

Eine Oberfläche verbindet Services, Modelle, Benutzer und Systemstatus.


Kubernetes liefert das Fundament.
Magic Stick macht es bedienbar.

UI • AKTUELL



Installieren, wo Sie schon sind.


Der Einstieg ändert sich. Der sichere Zielzustand bleibt gleich.



Der erste Admin entsteht bei Ihnen

Kein festes Standardkonto. Kein bekanntes Benutzerpasswort im Repository.

- **Konsolencode**
- **First Run**
- **Admin**
- **Lokaler Zugriff**
- **Keycloak**
- **SSO aktiv**




Ein Katalog macht Anwendungen beherrschbar

Module aktivieren. Instanzen erzeugen.
Status und URLs an einer Stelle sehen.

Abhängigkeiten werden automatisch geprüft.

Jede Instanz bleibt separat konfigurierbar.

SERVICES ·
AKTUELL



Konfigurieren, ohne Kubernetes lesen zu müssen

Auswählen, prüfen und freigeben – direkt im Dashboard.

01 Service instanziiieren

Create Instance
Choose the type of instance you want to create.

OpenClaw Unavailable. Enable and wait for: OpenClaw Operator.	Hermes Unavailable. Enable and wait for: Hermes Operator.	Paperclip Unavailable. Enable and wait for: Paperclip Operator, Agent Sandbox.
KubeOpenCode Unavailable. Enable and wait for: KubeOpenCode.	Odysseus Unavailable. Enable and wait for: Odysseus.	

Cancel

Typ, Modell, Zugriff und URL wählen.

02 Lokales Modell

Configure local model
NVIDIA GPU with VLLM selected. 2 allocatable NVIDIA GPU resource(s) available.

Name: qwen352bvlmembedding Type: embedding Preset: qwen352bvlmembedding Hugging Face URL: hf://LifetimeMistake/Qwen

Max Num Seqs: 8 Context Size: 4096

VRAM allocation High confidence

Minimum: 7.8 GiB Recommended: 9.8 GiB 100% unreserved: 23 GiB

Minimum 7.8 GiB Recommended 9.8 GiB 100% unreserved 23 GiB

The slider maximum equals 100% of unreserved VRAM

Engine, Compute-Ziel und Speicher festlegen.

03 Appliance prüfen

Appliance Control Connected

Overview Services Models Settings Users System Status

Appliance ai-system/local is Ready

Modules 5 modules enabled

Instances 0 instances requested

Models 0 models installed

Available URLs 4 URLs

Dashboard Module - Ready

LOCAL: https://magicstick.local

PUBLIC: https://magicstick.example.com

Zustand, URLs und Module auf einen Blick.

Externe Modelle. Ein gemeinsamer Zugang.

LiteLLM bündelt OpenAI-kompatible
Provider
hinter einem gemeinsamen
Modellzugang.

Keine lokale GPU erforderlich.
Anwendungen behalten denselben
Endpunkt.

EXTERN ·
OPENAI

Configure external model
Uses a remote provider through LiteLLM. No local GPU driver or KubeAI installation is required.

Name	Provider Model	API Base	Type
example-openai-gpt-4o-mini	openai/gpt-4o-mini	https://api.openai.com/v1	chat

Context	API Key
128000	CHANGEME


Add External Model

Ein Modellzugang. Mehrere Laufzeiten.

vLLM und Ollama werden nur
aktiviert,
wenn lokale Modelle sie wirklich
brauchen.

VLLM · CPU +
NVIDIA/AMD/INTEL

OLLAMA · CPU +
NVIDIA/AMD



Compute wechselt. Die Plattform bleibt.

Das Dashboard zeigt nur Kombinationen, die der Cluster wirklich bereitstellt.

01 CPU

vLLM · Ollama · ohne GPU-Treiber

02 NVIDIA

vLLM · Ollama · CUDA Operator

03 AMD

vLLM · Ollama · ROCm Operator

04 Intel

vLLM · Intel GPU Plugin

Modelle werden gegen echte Kapazität geplant

01

Unreserviert

Gesamtspeicher minus Modellreservierungen

02

Tatsächlich frei

Live-Metriken von CPU oder GPU


03

Minimum + Empfehlung

Regler zeigt Passform vor dem Start

RAM UND VRAM TRANSPARENT

AKTUELLE COMPUTE-MEMORY-ANSICHT



Wissen, Chat und Agenten

AnythingLLM, OpenClaw, Hermes, Paperclip, KubeOpenCode und Odysseus.

WISSEN + CHAT

AGENTEN + CODING

INSTANZEN NACH BEDARF



Lokales SSO schützt Dashboard und Services




Benutzer und Rollen bleiben im Control Plane

Anlegen, bearbeiten, deaktivieren,
Passwörter zurücksetzen und löschen.

Viewer, User, Operator und Admin
steuern den Zugriff auf die Plattform.

KEYCLOAK ·
ROLLEN



The screenshot shows the 'Create User' form in Keycloak. The form is titled 'Create User' and has a subtitle 'Create a local Keycloak user for this appliance.' It contains several input fields: 'Username', 'First name', 'Last name', 'Email', 'Access level' (a dropdown menu with 'User' selected), and 'Temporary password'. There is also a 'Confirm temporary password' field. At the bottom, there is a checkbox labeled 'Enable the account after it has been created' which is checked. The form has 'Cancel' and 'Create User' buttons at the bottom right.

Der Sollzustand bleibt versioniert

Von der Installation bis zum Modell wird jede Schicht reproduzierbar verwaltet.

01 Automation

USB · cloud-init · Install-Skripte

02 GitOps

Kubernetes/K3s · Flux

03 Identität

Envoy · Keycloak · First Run

04 AI Workloads


Operator · KubeAI · LiteLLM · Apps

Operatoren folgen der erkannten Hardware

NFD erkennt NVIDIA, AMD und Intel.
Der Status trennt installiert von nutzbar.

CPU bleibt unabhängig verfügbar.
GPU-Ziele erscheinen erst bei echter
Bereitschaft.

**HARDWARE ·
BEREIT**



Eine Plattform. Drei Lizenzstufen.

FREE

Vollständige AI-Appliance

BSL 1.1 mit Free Use Grant
Modelle, Nutzer, Sharing und Mesh
Bis 2 Mio. EUR Gruppenumsatz*
MIT nach 3 Jahren je Version

REGISTERED & COMMERCIAL

Federated SSO mit Lizenzdatei

Free Registered: kostenlose Datei
Commercial: außerhalb des Grants
Produktive Angebote für Dritte*
* Details: LICENSING.md

Zugriff folgt Teams und Ressourcen.

Lokale Nutzer und Gruppen erhalten Zugriff auf ausgewählte Instanzen.

GRUPPEN-RBAC

OHNE LIZENZDATEI



In drei Schritten zum belegbaren Nutzen

01

Use Case festlegen

Ziel, Nutzergruppe und Erfolgskriterien

02

Magic Stick bereitstellen

First Run, SSO, Modelle und Services


03

Wirkung nachweisen

Qualität, Geschwindigkeit, Kosten, Akzeptanz

PILOT AUF IHRER INFRASTRUKTUR

AKTUELLE PRODUKTOBERFLÄCHE



NÄCHSTER SCHRITT · PILOT

Bringen wir Ihre KI-Plattform unter Kontrolle.

Magic Stick im Pilot erproben. Lizenzbedingungen: LICENSING.md

hello@qualityminds.de

QUALITYMINDS