

OPEN SOURCE AI APPLIANCE

Ihre KI-Plattform. Einfach betreibbar.

Modelle, Services, Benutzer und Betrieb
auf Ihrer Infrastruktur.

LOCAL-FIRST

HYBRID

OPEN


QUALITYMINDS



Produktive KI ist mehr als ein Modell

Sechs Grenzen entscheiden, ob aus einem Experiment ein nutzbarer Dienst wird.

- Installation
- Netzwerk
- Modelle
- GitOps
- Identität
- Anwendungen




Ein Control Plane macht KI zur Appliance

Eine Oberfläche verbindet Services, Modelle, Benutzer und Systemstatus.


Kubernetes liefert das Fundament.
Magic Stick macht es bedienbar.

UI · AKTUELL



Installieren, wo Sie schon sind.


Der Einstieg ändert sich. Der sichere Zielzustand bleibt gleich.



Der erste Admin entsteht bei Ihnen

Kein festes Standardkonto. Kein bekanntes Benutzerpasswort im Repository.

- **Konsolencode**
- **First Run**
- **Admin**
- **Lokaler Zugriff**
- **Keycloak**
- **SSO aktiv**




Ein Katalog macht Anwendungen beherrschbar

Module aktivieren. Instanzen erzeugen.
Status und URLs an einer Stelle sehen.

Abhängigkeiten werden automatisch geprüft.
Jede Instanz bleibt separat konfigurierbar.

SERVICES ·
AKTUELL



Konfigurieren, ohne Kubernetes lesen zu müssen

Auswählen, prüfen und freigeben - direkt im Dashboard.

01 Service instanziiieren

Create Instance
Choose the type of instance you want to create.

Instance Type	Status	Description
OpenClaw	Unavailable. Enable and wait for: OpenClaw Operator.	
Hermes	Unavailable. Enable and wait for: Hermes Operator.	
Paperclip	Unavailable. Enable and wait for: Paperclip Operator, Agent Sandbox.	
KubeOpenCode	Unavailable. Enable and wait for: KubeOpenCode.	
Odysseus	Unavailable. Enable and wait for: Odysseus.	

Cancel

Typ, Modell, Zugriff und URL wählen.

02 Lokales Modell

Configure local model
NVIDIA GPU with VLLM selected. 2 allocatable NVIDIA GPU resource(s) available.

Name	Type	Preset	Hugging Face URL
qwen352bvlembedding	embedding	qwen352bvlembedding	hf://LifetimeMistake/Qwen

Max Num Seqs: 8
Context Size: 4096

VRAM allocation High confidence

Minimum	Recommended	100% unreserved
7.8 GiB	9.8 GiB	23 GiB

Minimum 7.8 GiB Recommended 9.8 GiB 100% unreserved 23 GiB

The slider maximum equals 100% of unreserved VRAM.

Engine, Compute-Ziel und Speicher festlegen.

03 Appliance prüfen

Appliance Control Connected

Overview	Appliance	Modules	Instances	Models
Services	ai-system/local is Ready	5 modules enabled	0 instances requested	0 models installed
Models				
Settings				
Users				
System Status				

Available URLs 4 URLs

Dashboard	Module	Ready	LOCAL	PUBLIC
https://magicstick.local				
https://magicstick.example.com				

Zustand, URLs und Module auf einen Blick.

Externe Modelle. Ein gemeinsamer Zugang.

LiteLLM bündelt OpenAI-kompatible
Provider
hinter einem gemeinsamen
Modellzugang.

Keine lokale GPU erforderlich.
Anwendungen behalten denselben
Endpunkt.

EXTERN ·
OPENAI

Configure external model
Uses a remote provider through LiteLLM. No local GPU driver or KubeAI installation is required.

Name	Provider Model	API Base	Type
example-openai-gpt-4o-mini	openai/gpt-4o-mini	https://api.openai.com/v1	chat

Context	API Key
128000	CHANGEME

Add External Model

Ein Modellzugang. Mehrere Laufzeiten.

vLLM und Ollama werden nur
aktiviert,
wenn lokale Modelle sie wirklich
brauchen.

VLLM • CPU +
NVIDIA/AMD/INTEL

OLLAMA • CPU +
NVIDIA/AMD



Compute wechselt. Die Plattform bleibt.

Das Dashboard zeigt nur Kombinationen, die der Cluster wirklich bereitstellt.

01 CPU

vLLM · Ollama · ohne GPU-Treiber

02 NVIDIA

vLLM · Ollama · CUDA Operator

03 AMD

vLLM · Ollama · ROCm Operator

04 Intel

vLLM · Intel GPU Plugin

Modelle werden gegen echte Kapazität geplant

01

Unreserviert

Gesamtpeicher minus Modellreservierungen

02

Tatsächlich frei

Live-Metriken von CPU oder GPU


03

Minimum + Empfehlung

Regler zeigt Passform vor dem Start

RAM UND VRAM TRANSPARENT

AKTUELLE COMPUTE-MEMORY-ANSICHT



Wissen, Chat und Agenten

AnythingLLM, OpenClaw,
Hermes,
Paperclip, KubeOpenCode und
Odysseus.

WISSEN + CHAT

AGENTEN + CODING

INSTANZEN NACH BEDARF



Lokales SSO schützt Dashboard und Services



Benutzer und Rollen bleiben im Control Plane

Anlegen, bearbeiten, deaktivieren,
Passwörter zurücksetzen und löschen.

Viewer, User, Operator und Admin
steuern den Zugriff auf die Plattform.

**KEYCLOAK ·
ROLLEN**

The screenshot shows the 'Create User' form in Keycloak. The form is titled 'Create User' and has a subtitle 'Create a local Keycloak user for this appliance.' The form contains several input fields: 'Username', 'First name', 'Last name', 'Email', 'Access level' (a dropdown menu with 'User' selected), 'Temporary password', and 'Confirm temporary password'. There is also a checkbox labeled 'Enable the account after it has been created' which is checked. At the bottom right of the form are two buttons: 'Cancel' and 'Create User'.

Der Sollzustand bleibt versioniert

Von der Installation bis zum Modell wird jede Schicht reproduzierbar verwaltet.

01 Automation

USB · cloud-init · Install-Skripte

02 GitOps

Kubernetes/K3s · Flux

03 Identität

Envoy · Keycloak · First Run

04 AI Workloads


Operator · KubeAI · LiteLLM · Apps

Operatoren folgen der erkannten Hardware

NFD erkennt NVIDIA, AMD und Intel.
Der Status trennt installiert von nutzbar.

CPU bleibt unabhängig verfügbar.
GPU-Ziele erscheinen erst bei echter
Bereitschaft.

**HARDWARE ·
BEREIT**



Open Source liefert die Plattform. Enterprise die Governance.

COMMUNITY

Vollständige AI-Appliance

Magic-Stick-Code unter MIT
Services, Modelle und Benutzer
Globale Rollen + Mindestrolle je Instanz
Vollständig selbst betreibbar

ENTERPRISE · IN KONZEPTION

Governance für Organisationen

Nutzer/Gruppen je Ressource
Organisatorische Scopes
Delegierte Admins · Richtlinien · Audit
Preise auf Anfrage

Zugriff folgt Teams und Ressourcen.

Nutzer und IdP-Gruppen werden konkreten Services, Instanzen und Modellen zugeordnet.

GRUPPEN-RBAC

DELEGIERTE ADMINS



In drei Schritten zum belegbaren Nutzen

01

Use Case festlegen

Ziel, Nutzergruppe und Erfolgskriterien

02

Magic Stick bereitstellen

First Run, SSO, Modelle und Services


03

Wirkung nachweisen

Qualität, Geschwindigkeit, Kosten, Akzeptanz

PILOT AUF IHRER INFRASTRUKTUR

AKTUELLE PRODUKTOBERFLÄCHE



NÄCHSTER SCHRITT · PILOT

Bringen wir Ihre KI-Plattform unter Kontrolle.

Open Source ausprobieren · Pilot und Enterprise auf Anfrage

hello@qualityminds.de

QUALITYMINDS

