

OPEN SOURCE AI APPLIANCE

Ihre KI-Plattform. Unter Ihrer Kontrolle.

Auf eigener Hardware, in der Cloud
oder im vorhandenen Kubernetes-Cluster.

LOCAL-FIRST

HYBRID

OPEN


QUALITYMINDS



Die Herausforderung ist nicht das Modell

Produktive KI entsteht erst, wenn sechs technische Grenzen zusammenspielen.

- Installation
- Netzwerk
- Modelle
- GitOps
- Identität
- Anwendungen




Eine Oberfläche steuert die Appliance

Module aktivieren. Modelle verbinden.
Instanzen bereitstellen. Benutzer
verwalten.


Kubernetes bleibt das Fundament.
Der Nutzer arbeitet im Dashboard.

CONNECTED



Vier Zielumgebungen. Ein Installationspfad.

Magic Stick passt sich der Infrastruktur an – nicht umgekehrt.




Lokal. Cloud. Austauschbar.

LiteLLM bündelt Provider.
KubeAI startet lokale Modelle erst
bei Bedarf.

GPU-NEUTRALE BASIS

OPENAI-KOMPATIBEL



Vier Schichten. Wiederholbarer Betrieb.

Jede Schicht hat eine klare Aufgabe – und einen versionierten Sollzustand.

01 Automation

Installer + Ansible

02 GitOps

K3s + Flux

03 Identität

Envoy + Keycloak

04 AI Workloads

LiteLLM + KubeAI + Apps

Chat, Agenten und Coding

Instanzen erhalten eine eigene URL, SSO und ein ausgewähltes Modell.

ANYTHINGLLM

OPENCLAW · HERMES

PAPERCLIP · KUBEOPENCODE



SSO schützt Dashboard und Anwendungen



Open Source liefert die Plattform. Enterprise die Governance.

COMMUNITY

Vollständige AI-Appliance

Lokales SSO und Benutzerverwaltung
Module, Modelle und Instanzen
Owner-only oder alle angemeldeten Nutzer
MIT-Lizenz

ENTERPRISE · AUF ANFRAGE

Governance für Organisationen

Freigaben pro Modul und Instanz
Benutzer- und Gruppen-RBAC
IdP-Gruppenzuordnung
Delegierte Administration
Preise auf Anfrage

ENTERPRISE · AUF ANFRAGE

Teams sehen nur, was sie brauchen.

Rollen pro Modul und Instanz:
Viewer · User · Operator · Admin

IDP-GRUPPEN


DELEGIERTE ADMINS



Neue Ressourcen entstehen geführt statt über YAML

Auswählen, konfigurieren und freigeben – direkt im Dashboard.

01 Instanz auswählen



Create Instance
Choose the type of Instance you want to create.

OpenClaw
Configure a new OpenClaw Instance.

Hermes
Configure a new Hermes Instance.

Paperclip
Configure a new Paperclip Instance.


KubeOpenCode
Configure a new KubeOpenCode Instance.

Odysseus
Configure a new Odysseus Instance.

Cancel

Anwendungstyp aus dem Katalog wählen.

02 Modell konfigurieren



Create Model
Local presets and external providers

Local Model
Local models are unavailable. Enable and wait until these modules are Ready: Gpu, Kubeal.

Name: qwen352bvlembdding Preset: qwen352bvlembdding

Type: chat VRAM Limit: 5Gi

Hf URL: hf://example/model Context Size: 4096

Max Num Seqs: 32

VRAM Estimate: Waiting for model metadata

External Model
Uses a remote provider through LiteLLM. No local GPU driver or KubeAI installation is required.

Name: example-openai-gpt-4o-mini Provider Model: openai/gpt-4o-mini

API Base: https://api.openai.com/v1 Type: chat


Context: 128000 API Key: CHANGEME

Add External Model

Create

Lokale oder externe Modellquelle anbinden.

03 Benutzer anlegen



Create User
Create a local Keycloak user for this appliance.

Username: First name: Last name:

Email: Access level: User Temporary password:

Confirm temporary password:

☒ Enable the account after it has been created

Cancel Create User

Rolle und ersten Zugang zentral vergeben.

In drei Schritten zum messbaren Pilotbetrieb

01

Pilot festlegen

Use Case, Nutzergruppe und Zielumgebung

02

Magic Stick bereitstellen

Installation, SSO und gewünschte Modellquellen


03

Nutzen nachweisen

Qualität, Geschwindigkeit, Kosten und Akzeptanz messen

PILOT AUF IHRER INFRASTRUKTUR

ECHTER TESTSERVER · MODELL BEREIT



NÄCHSTER SCHRITT · PILOT

Bringen wir Ihre KI-Plattform unter Kontrolle.

Pilot auf Ihrer Infrastruktur · Preise und Umfang auf Anfrage

hello@qualityminds.de

QUALITYMINDS