

OPEN SOURCE AI APPLIANCE

Ihre KI-Plattform. Unter Ihrer Kontrolle.

Auf eigener Hardware, in der Cloud
oder im vorhandenen Kubernetes-Cluster.

LOCAL-FIRST

HYBRID

OPEN

QUALITYMINDS



Die Herausforderung ist nicht das Modell

Produktive KI entsteht erst, wenn sechs technische Grenzen zusammenspielen.

- Installation
- Netzwerk
- Modelle
- GitOps
- Identität
- Anwendungen

```

magicstick-autopilot-20260804

^get time-set.target - System Time Set.
systemd-resolved.service - Network Name Resolution.
^get nss-lookup.target - Host and Network Name Lookups.
on systemd-rfkill.socket - Load/Save RF Kill Switch Status /dev/rfkill Watch.
apparmor.service - Load AppArmor profiles.
nbd.service - Load AppArmor profiles managed internally by snapd...
loud-init-local.service - Cloud-Init: Local Stage (pre-network)...
loud-init-local.service - Load AppArmor profiles managed internally by snapd.
j-init[660]: Cloud-Init v. 25.2-0ubuntu1~24.04.1 running 'init-local' at Tue, 04 Aug 2026 21:16:52 +0000. Up 0.24 seconds.
loud-init-local.service - Cloud-Init: Local Stage (pre-network).
^get network-pre.target - Preparation for Network.
systemd-networkd.service - Network Configuration...
systemd-networkd.setenv - NetworkdConf oration.
systemd-networkd.service - Network Configuration...
systemd-networkd.service - Network Configuration.
^get network.target - Network.
systemd-networkd-wait-online.service - Wait for Network to be Configured...
systemd-networkd-wait-online.service - Wait for Network to be Configured.
loud-init.service - Cloud-Init: Network Stage...
j-init[724]: Cloud-Init v. 25.2-0ubuntu1~24.04.1 running 'init' at Tue, 04 Aug 2026 21:16:54 +0000. Up 10.70 seconds.
j-init[724]: ci-Info: +-----+Net device info+-----+
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: | Device | Up | Address | Mask | Scope | Hw-Address |
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: | enp0s1 | True | 192.168.205.7 | 255.255.255.0 | global | 06:e2:e2:08:04:2a |
j-init[724]: ci-Info: | enp0s1 | True | fe80::4e2:e2ff:fe08:42a/64 | . | link | 06:e2:e2:08:04:2a |
j-init[724]: ci-Info: | lo | True | 127.0.0.1 | 255.0.0.0 | host | . |
j-init[724]: ci-Info: | lo | True | ::1/128 | . | host | . |
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: +-----+Route IPv4 info+-----+
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: | Route | Destination | Gateway | Genmask | Interface | Flags |
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: | 0 | 0.0.0.0 | 192.168.205.1 | 0.0.0.0 | enp0s1 | UG |
j-init[724]: ci-Info: | 1 | 192.168.205.0 | 0.0.0.0 | 255.255.255.0 | enp0s1 | U |
j-init[724]: ci-Info: | 2 | 192.168.205.1 | 0.0.0.0 | 255.255.255.255 | enp0s1 | UH |
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: +-----+Route IPv6 info+-----+
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: | Route | Destination | Gateway | Interface | Flags |
j-init[724]: ci-Info: +-----+
j-init[724]: ci-Info: +-----+

```

SICHERER FIRST RUN · KEIN DEFAULT-PASSWORT


Eine Oberfläche steuert Services, Modelle und Benutzer

Services bündeln Module und Instanzen.

Modelle nutzen nur verfügbare Hardware.


SSO und Rollen schützen die Zugänge.
Kubernetes bleibt das Fundament.

**AKTUELLER
STAND**



Vier Startpunkte. Ein Zielzustand.

USB, Cloud-init, Ubuntu-Skript oder vorhandenes Kubernetes.



Ein Modellzugang. Mehrere Laufzeiten.

LiteLLM bündelt externe Provider.
KubeAI startet lokale Modelle nur
bei Bedarf.

VLLM · CPU + 3
GPU-TYPEN

OLLAMA · CPU +
NVIDIA/AMD



Vier Schichten. Wiederholbarer Betrieb.

Von der Installation bis zum Modell bleibt der Sollzustand versioniert.

01 Automation

USB · cloud-init · Install-Skripte

02 GitOps

Kubernetes/K3s · Flux

03 Identität

Envoy · Keycloak · First Run

04 AI Workloads

Operator · KubeAI · LiteLLM · Apps

Chat, Agenten und Coding

AnythingLLM bündelt Wissen.
OpenClaw, Hermes, Paperclip,
KubeOpenCode · Odysseus.

ANYTHINGLLM

OPENCLAW · HERMES

PAPERCLIP · KUBEOPENCODE



Lokales SSO schützt jede Route



Open Source liefert die Plattform. Enterprise die Governance.

COMMUNITY

Vollständige AI-Appliance

Magic-Stick-Code unter MIT
Services, Modelle und Benutzer
Globale Rollen + Mindestrolle je Instanz
Vollständig selbst betreibbar

ENTERPRISE · IN KONZEPTION

Governance für Organisationen

Nutzer/Gruppen je Ressource
Organisatorische Scopes
Delegierte Admins · Richtlinien · Audit
Preise auf Anfrage

Zugriff folgt Teams und Ressourcen.

Nutzer und IdP-Gruppen werden konkreten Services und Instanzen zugeordnet.

GRUPPEN-RBAC

DELEGIERTE ADMINS



Services, Modelle und Benutzer entstehen geführt

Auswählen, konfigurieren und freigeben – ohne YAML.

01 Service instanziiieren

Create Instance
Choose the type of instance you want to create.

OpenClaw Unavailable. Enable and wait for: OpenClaw Operator.	Hermes Unavailable. Enable and wait for: Hermes Operator.	Paperclip Unavailable. Enable and wait for: Paperclip Operator, Agent Sandbox.
---	---	--

KubeOpenCode
Unavailable. Enable and wait for: KubeOpenCode.

Odysseus
Unavailable. Enable and wait for: Odysseus.

Cancel

Typ, Modell, Rolle und URL konfigurieren.

02 Modell + Compute

Configure local model
NVIDIA GPU with VLLM selected. 2 allocatable NVIDIA GPU resource(s) available.

Name: qwen352bvlmbedding Type: embedding Preset: qwen352bvlmbedding Hugging Face URL: hf://LifetimeMistake/Qwen

Max Num Seqs: 8 Context Size: 4096

VRAM allocation High confidence

Minimum: 7.8 GiB Recommended: 9.8 GiB 100% unreserved: 23 GiB

Minimum 7.8 GiB Recommended 9.8 GiB 100% unreserved 23 GiB

The slider maximum equals 100% of unreserved VRAM.

Cancel

Engine, verfügbare Hardware und Speicher wählen.

03 Benutzer verwalten

Create User
Create a local Keycloak user for this appliance.

Username: First name: Last name:

Email: Access level: User Temporary password:

Confirm temporary password:

☒ Enable the account after it has been created

Cancel Create User

Anlegen, Rollen ändern, deaktivieren oder löschen.

In drei Schritten zum belegbaren Pilotbetrieb

01

Pilot festlegen

Use Case, Nutzergruppe und Zielumgebung

02

Magic Stick bereitstellen

First Run, SSO, externe oder lokale Modelle

03

Nutzen nachweisen

Qualität, Geschwindigkeit, Kosten und Akzeptanz

PILOT AUF IHRER INFRASTRUKTUR

AKTUELLE UI · BEISPIELKONFIGURATION



NÄCHSTER SCHRITT · PILOT

Bringen wir Ihre KI-Plattform unter Kontrolle.

Pilot auf Ihrer Infrastruktur · Preise und Umfang auf Anfrage

hello@qualityminds.de

QUALITYMINDS